

통계적 기계학습 기반
자동차 보험 사기 탐지 분류 모델
비교 연구

Logit Adjustment 적용 및 분석

*Logit Adjustment for Insurance Fraud Detection
under Severe Class Imbalance*

12214256 최진호 / 12241701 박준형

인하대학교 데이터사이언스학과

통계적 기계학습 | 담당교수: 김재오

2026년 1학기

요 약

본 연구는 자동차 보험 사기 데이터의 극심한 클래스 불균형(사기 비율 5.99%) 환경에서, 인위적 데이터 증강 없이, 학습된 분류기의 출력에 사후적으로 Logit Adjustment를 적용하여 클래스 불균형으로 인한 편향을 완화하는 방법을 검증한다. 구체적으로 [Menon et al. \(2021\)](#)이 제안한 Logit Adjustment를 자동차 보험 사기 데이터에 적용하고, Baseline 및 Class-Weighted 방식과 비교하였다. Stratified 5-Fold 교차검증과 Test 20% Holdout 평가를 결합하여, Elastic Net Logistic Regression, Random Forest, CatBoost 세 모델에 세 가지 보정 방법을 적용한 9개 조합의 성능을 비교하였다. 비대칭 오분류 비용($C_{FN}=10, C_{FP}=1$)을 반영한 경험적 비용 지표(Cost)를 Recall, F_2 , G-Mean, PR-AUC와 함께 평가 지표로 사용하였다.

핵심 결과는 다음과 같다. CatBoost + Logit Adjustment 조합이 Holdout 비용 지표(Cost) 0.3304로 최저값을 달성하였으며, 이는 Baseline(0.5781) 대비 42.9%, Class Weighted(0.3567) 대비 7.4% 감소이다. 5-Fold 평가에서 Logit Adjustment의 표준편차 $\sigma(\text{Cost})=0.0082$ 로 Class Weighted의 $\sigma=0.0149$ 의 절반 수준에 머물러 일반화 안정성도 우수하였다. 변수 중요도 분석 결과 두 방법 모두 Fault를 핵심 변수로 일관되게 식별하였으며, 도메인 검증에서 Fault=Policy Holder의 실제 사기율이 Third Party의 약 8.9배로 나타나 모델이 학습한 패턴이 도메인 지식과 일치함을 확인하였다.

핵심어: 보험 사기 탐지, *Logit Adjustment*, 클래스 불균형, 비대칭 오분류 비용 지표, 편향-분산 트레이드오프

본 결과는 데이터 증강이나 손실함수 변경 없이 사전확률 정보만으로 극심한 클래스 불균형을 효과적으로 보정할 수 있음을 보여주며, 실제 보험 사기 탐지 시스템 설계에 실용적 지침을 제공한다.

목 차

요약	1
1 서론	4
2 관련 연구	5
3 데이터 및 탐색적 데이터 분석	7
3.1 데이터 소개	7
3.2 데이터 전처리 및 수치 변환	8
3.3 탐색적 데이터 분석 결과	8
3.3.1 사기 건수 분포 및 클래스 불균형	8
3.3.2 카이제곱 검정 — 어떤 변수가 사기와 관련 있는가	9
3.3.3 변수별 사기 패턴 분석	10
3.3.4 변수-사기 간 상관관계 분석	12
4 방법론	14
4.1 Logit Adjustment의 수학적 정의	14
4.1.1 관별적 접근과 생성적 접근의 융합	15
4.2 비교 방법론	15
4.3 비대칭 오분류 비용 지표	16
4.4 모델 평가 지표	16
5 모델 학습 및 결과	17
5.1 실험 설계	17
5.1.1 하이퍼파라미터 탐색	17
5.2 성능 결과	18
5.2.1 Holdout 평가 결과	18
5.2.2 5-Fold 교차검증: 일반화 안정성	19
5.2.3 보정 전후 확률 분포 변화	20
5.2.4 최종 모델 Confusion Matrix	21
6 변수 중요도 분석	23
6.1 Top 15 변수 비교	23
6.2 도메인 검증	24

7 결론	25
7.1 요약	25
7.2 한계 및 향후 과제	25

Chapter 1

서론

자동차 보험 사기는 고의적 사고 조작, 피해 금액 부풀리기, 허위 청구 등 다양한 형태로 발생하며 보험사의 재정 건전성을 위협하고 선량한 가입자들의 보험료 인상을 초래하는 사회적 문제이다. 미국 보험연구원(Insurance Research Council)에 따르면 자동차 보험 사기로 인한 연간 손실은 수십억 달러 규모로 추정된다. 기존의 수작업 심사나 규칙 기반 방식은 사기 수법이 다양해지고 처리해야 할 데이터 양이 늘어날수록 한계가 명확하다.

이러한 배경에서 기계학습을 활용한 자동 탐지 시스템이 핵심 대안으로 주목받아 왔다. Mitchell (1997)이 정의한 바와 같이 “경험 E 를 통해 작업 T 에서의 성능 P 가 향상되는” 학습 패러다임은, 과거의 방대한 보험 청구 기록이라는 “경험 E ”을 바탕으로 새로운 청구 건의 사기 여부를 판별하는 “작업 T ”을 수행하며, 단순 정확도가 아닌 실제 사기 적발 “성능 P ”을 극대화하는 본 연구의 문제 정의에 정확히 부합한다.

그러나 보험 청구 데이터에는 사고 발생 시점, 차량 정보, 계약 조건, 청구자 정보 등 다양한 변수가 섞여 있고, 본 연구에 사용된 데이터는 사기 비율이 약 5.99%에 불과한 극심한 클래스 불균형(Class Imbalance) 문제를 안고 있다. 이 경우 모든 청구를 “정상”으로 덮어놓고 분류하는 모델조차 90% 이상의 정확도를 달성할 수 있어, 단순 정확도(Accuracy)는 실제 탐지 성능을 제대로 반영하지 못한다. Krawczyk (2016)이 강조한 것처럼, 이와 같이 극단적으로 불균형한 데이터셋은 이진 분류 문제에서 매우 심각한 도전 과제를 제기한다.

이러한 맥락에서 본 연구는 다음 세 가지를 주요 목적으로 설정하였다. 첫째, 데이터에 대한 체계적 탐색 및 전처리 수행. 둘째, 데이터 증강 없이 학습된 모델의 출력만을 사후 보정하는 Logit Adjustment(Menon et al., 2021)를 적용하여 클래스 불균형에 대응. 셋째, 사기 미탐지 비용이 정상 오탐지 비용보다 크다는 비즈니스 현실을 반영한 비대칭 오분류 비용 지표(Cost)를 추가 평가 지표로 설정하여 비교. 또한 모델의 예측 오차를 편향(Bias)과 분산(Variance)의 관점에서 해석하여 모델 선택의 이론적 근거를 제시한다.

논문의 구성은 다음과 같다. 2장에서 관련 선행 연구를 검토하고, 3장에서 데이터 소개, 전처리, EDA 결과를 기술한다. 4장에서 Logit Adjustment의 수학적 정의와 비교 방법론을 설명하며, 5장에서 모델 결과를 제시하고 6장에서 변수 중요도를 분석한다. 7장에서 결론과 향후 과제를 논의한다.

Chapter 2

관련 연구

금융 및 보험 사기 탐지에 기계학습을 도입하려는 시도는 오랜 기간 활발히 진행되어 왔다. Ngai et al. (2011)는 금융, 보험, 통신 분야의 광범위한 문헌을 분석해 로지스틱 회귀, 의사결정나무, 신경망 등이 사기 적발에 유용하게 쓰이고 있음을 확인하였다. 특히 실무 현장에서는 특정 알고리즘 하나에만 의존하기보다, 다양한 접근법을 교차 검증하는 것이 훨씬 효과적이라는 점이 입증된 바 있다.

이 분야의 데이터를 다룰 때 가장 고질적인 장애물은 클래스 불균형(Class Imbalance)이다. Krawczyk (2016)은 불균형 데이터가 초래하는 학습의 왜곡을 지적하며, 단순 정확도 대신 소수 클래스 탐지력을 보여주는 지표(G-mean, F-measure 등)를 반드시 활용해야 한다고 권고했다. 사기 탐지 문제에선 두 유형의 오분류가 동일한 의미를 가지지 않는다. 정상 데이터를 사기로 잘못 분류하는 False Positive(FP)는 고객 불편, 추가 심사 비용, 운영 효율 저하 등의 문제를 유발하나 실제 사기를 정상으로 판단하는 False Negative(FN)는 직접적인 보험금 손실로 이어질 수 있다. Salem (2017)은 금융 및 사기 탐지 문제에서 FN의 비용이 FP보다 훨씬 크기에, 단순히 정확도를 기반으로 하는 평가는 이런 비용적 차이를 반영하지 못한다고 지적했다. 이에 따라 최근의 사기 탐지 연구에서는 오분류 비용의 비대칭성을 고려한 접근이 활용되고 있다. 이 불균형을 해소하기 위한 대표적인 오버샘플링 기법으로 Chawla et al. (2002)의 SMOTE가 널리 쓰여 왔다. 이는 소수 클래스 주변에 가상의 데이터를 생성해 숫자를 맞추는 원리이다. 이후 ADASYN이나 BorderlineSMOTE 등 발전된 방식들이 등장했으나, 여전히 소수 클래스 내부의 군집 구조를 무시한 채 데이터를 생성하여 실제 분포와 동떨어진 노이즈를 만들 수 있다는 약점이 존재했다.

이러한 데이터 증강 기반 접근의 한계를 극복하기 위해, 최근에는 모델 출력을 사후에 보정하는 *post-hoc correction* 계열 기법이 주목받고 있다. Menon et al. (2021)은 long-tail 학습 환경에서 Logit Adjustment 기법을 제안하였는데, 이는 학습 데이터의 사전확률 π 만으로 분류기의 logit을 사후 보정하여 균형 분포에서의 Bayes 결정 경계로 이동시킨다. 이 기법은 데이터 자체를 변경하지 않고 학습된 모델 출력만을 조정하므로 SMOTE와 같은 합성 샘플로 인한 분포 왜곡 위험이 없으며, 어떤 분류기에도 적용 가능하다는 실용적 장점을 가진다.

교차검증 기반 모델 비교에서는 평균 성능뿐만 아니라 성능 추정치의 분산 역시 중요한 평가 요소로 고려된다. (Bengio and Grandvalet, 2004)는 K-Fold 교차검증의 성능 추정치가 데이터 분할에 따라 변동될 수 있으며 하나의 평균값만으론 모델의 일반화에 대한 안정성을 충분히 설명하기 어렵다고 지적했다. 이후 분류 모델 비교 연구에선 평균 성능과 폴드 간 표준편차를 함께 제시해 모델의 안정성과 재현 가능성을 평가하는 접근

이 활용되고 있다. 본 연구 역시 비용 기반 성능지표에 대해 K-Fold 교차검증의 평균과 표준편차를 함께 비교하여 평균 성능과 데이터 분할에 따른 모델의 안정성을 종합적으로 분석하였다.

Chapter 3

데이터 및 탐색적 데이터 분석

3.1 데이터 소개

분석에 사용한 데이터는 `fraud_oracle.csv`로, 미국 자동차 보험 청구 기록을 바탕으로 구성된 공개 데이터셋이다. 원본 데이터는 15,420건의 청구 기록과 33개 변수로 이루어져 있으며, 예측하고자 하는 결과(종속변수)인 `FraudFound_P`는 사기 여부를 0(정상)과 1(사기)로 나타낸 이진 변수이다. 나머지 32개 변수(독립변수)는 사고가 언제 어디서 일어났는지, 어떤 차량인지, 보험 계약 조건은 무엇인지, 청구자는 어떤 사람인지 등 네 가지 범주로 구성되어 있다. 각 변수와 수치 변환 방식은 표 3.1에 정리하였다.

표 3.1: 주요 변수 설명 및 수치 변환 방식

변수명	유형	인코딩	설명
Month / DayOfWeek	범주형	sin/cos 순환	사고 발생 월 · 요일
AccidentArea	범주형	이진	도심(1) / 외곽(0)
Make	범주형	원-핫	차량 제조사 브랜드
VehicleCategory	범주형	원-핫	Sedan, Sport, Utility 등
VehiclePrice	범주형	순서형	차량 가격 구간
AgeOfVehicle	범주형	순서형	차량 연식 구간
PolicyType	범주형	원-핫	All Perils, Collision, Liability
BasePolicy	범주형	원-핫	기본 보험 유형
Deductible	수치형	그대로	자기부담금(\$)
Fault	범주형	이진	가입자 과실(1) / 제3자 과실(0)
PastNumberOfClaims	범주형	순서형	과거 보험 청구 횟수
AddressChange_Claim	범주형	구간 중간값	청구 전후 주소 변경 기간
PoliceReportFiled	범주형	이진	경찰 신고 여부
WitnessPresent	범주형	이진	목격자 존재 여부
AgentType	범주형	이진	외부 대리점(1) / 내부 직원(0)
Days_Policy_Accident	범주형	구간 중간값	보험 가입 후 사고까지 기간
Age	수치형	0 → 16.5 보정	청구자 나이
Sex	범주형	이진	여성(1) / 남성(0)
MaritalStatus	범주형	원-핫	혼인 상태
AgeOfPolicyHolder	범주형	구간 중간값	보험 가입자 연령대
DriverRating	수치형	그대로	운전자 등급 (1~4)
NumberOfCars	범주형	구간 중간값	보유 차량 수
FraudFound_P	이진형	종속변수	사기 여부 (0/1)

3.2 데이터 전처리 및 수치 변환

기계학습 모델은 숫자만 처리할 수 있기 때문에 “도심/외곽”, “기혼/미혼” 처럼 글자로 되어 있는 범주형 변수를 모두 숫자로 바꾸는 작업이 필요하다. 그 전에 잘못 기록된 데이터를 먼저 정리하였다. 전처리와 변환 과정을 단계별로 표 3.2에 정리하였다. 탐색적 분석은 전처리 이전의 원본 범주형 변수를 기준으로 수행하였으며, 모델 학습용 수치 변환은 이 절에서 별도로 기술한다.

표 3.2: 데이터 전처리 및 수치 변환 절차

단계	수행 내용	판단 근거
①	DayOfWeekClaimed='0' 건 제거	요일은 Monday~Sunday 만 유효
②	PolicyNumber 제거	1~15,420 순차 ID로 데이터 누수 위험
③	Age=0 인 319 건을 16.5로 보정	해당 행의 AgeOfPolicyHolder가 모두 “16~17세”
④	이진 변환	Sex, Fault 등 6개 변수를 0/1로
⑤	순서형 인코딩	청구 횟수, 차량 가격, 연식 등 순서 있는 범주
⑥	구간 중간값 대체	“15~30일” → 22.5 등
⑦	sin/cos 순환 변환	Month, DayOfWeek 등 시간 변수
⑧	원-핫 인코딩	Make, MaritalStatus 등 5개 명목형
⑨	StandardScaler 표준화	변수 간 스케일 차이 보정
⑩	Stratified 80/20 분할	사기 비율 유지하며 Train/Test 분리

특히 시간 변수의 sin/cos 변환은 다음 식으로 정의하였다. 변수 t 의 주기를 T 라 하면,

$$t_{\sin} = \sin\left(\frac{2\pi t}{T}\right), \quad t_{\cos} = \cos\left(\frac{2\pi t}{T}\right). \quad (3.1)$$

이는 12월($t = 12$)과 1월($t = 1$)이 선형 인코딩에서는 11만큼 떨어져 있지만 실제로는 인접한 시점이라는 순환성을 반영하기 위함이다. 최종 학습 행렬은 $12,335 \times 67$ (Train), $3,084 \times 67$ (Test)이다.

3.3 탐색적 데이터 분석 결과

3.3.1 사기 건수 분포 및 클래스 불균형

분석 전 가장 먼저 확인한 것은 사기 건수의 비율이다. 표 3.3에서 보듯 전체 15,419 건 중 사기는 923건(5.99%)에 불과하고, 나머지 14,496건(94.01%)은 정상 청구이다. 이러한 한쪽 비율이 압도적으로 높은 상황을 “클래스 불균형”이라고 한다.

이 상태에서 단순히 “모든 청구를 정상으로 분류하는” 모델조차 94%의 정확도를 달성한다. 따라서 정확도(Accuracy) 하나만으로는 모델이 사기를 실제로 얼마나 잡아내는지 알 수 없다. 이후 모델 평가에서는 사기를 실제로 얼마나 찾아냈는지(Recall), 사기라고

표 3.3: 클래스 분포

클래스	건수	비율(%)	비고
0 (정상)	14,496	94.01%	다수 클래스
1 (사기)	923	5.99%	소수 클래스
합계	15,419	100%	오류 행 1건 제거 후

예측한 것 중 실제 사기 비율(Precision), 그리고 두 클래스를 균형 있게 탐지했는지를 반영하는 G-Mean과 PR-AUC, 비즈니스 손실을 반영한 비용 지표(Cost)를 평가 기준으로 사용한다.

3.3.2 카이제곱 검정 — 어떤 변수가 사기와 관련 있는가

33개 독립변수 중 실제로 사기와 의미 있는 관계가 있는 변수를 골라내기 위해 카이제곱 검정을 실시하였다. 카이제곱 검정은 두 변수 사이에 관계가 있는지를 통계적으로 확인하는 방법으로, p -value가 0.05보다 작으면 “우연이 아닌 실제 관계가 있다”고 판단한다. 검정 결과는 표 3.4와 같다.

표 3.4: 카이제곱 검정 결과 (사기와 유의한 관계를 가진 변수 상위 15)

변수명	χ^2 통계량	p -value	유의 여부
PolicyType (보험 종류)	437.49	< 0.001	유의
BasePolicy (기본 보험 유형)	402.95	< 0.001	유의
VehicleCategory (차량 종류)	290.98	< 0.001	유의
Fault (과실 여부)	264.99	< 0.001	유의
AddressChange_Claim (주소 변경)	104.72	< 0.001	유의
Deductible (자기부담금)	72.41	< 0.001	유의
VehiclePrice (차량 가격)	67.84	< 0.001	유의
Make (차량 제조사)	59.82	< 0.001	유의
PastNumberOfClaims (과거 청구 횟수)	53.54	< 0.001	유의
MonthClaimed (청구 월)	42.20	< 0.001	유의
AgeOfPolicyHolder (보험 가입자 나이)	33.10	< 0.001	유의
Month (사고 발생 월)	29.77	< 0.01	유의
AgeOfVehicle (차량 연식)	22.00	< 0.01	유의
NumberOfSupplements (추가 서류 수)	18.16	< 0.001	유의
AccidentArea (사고 지역)	16.90	< 0.001	유의
WeekOfMonth, MaritalStatus 등		≥ 0.05	비유의 (제외)

과실 여부(Fault), 보험 종류(PolicyType), 주소 변경(AddressChange_Claim), 과거 청구 횟수(PastNumberOfClaims), 연도(Year) 등 표에는 상위 15개 변수만 제시하였으며, 전체적으로는 총 21개의 변수가 사기 여부와 통계적으로 유의한 관계를 보였다. 반면, 혼인 상태(MaritalStatus), 주차(WeekOfMonth) 등은 p -value가 0.05 이상으로 도출되어 유의하지 않은 것으로 관찰되었다. 카이제곱 검정은 개별 변수의 독립적 연관성을 측정하는 반면, Feature Importance는 다른 변수들이 통제된 상태에서의 기여도를 반영하므로

두 분석의 순위가 다를 수 있다.

3.3.3 변수별 사기 패턴 분석

유의성이 확인된 변수들에 대해 집단별 사기율을 시각화하여 사기 행동 패턴을 구체적으로 파악하였다. 핵심 발견 사항을 표 3.5에 정리하였고, 그림 3.1~3.5에 시각화 결과를 제시한다.

표 3.5: 주요 변수별 사기 패턴 분석 결과

변수	주요 발견	해석
Fault (과실 여부)	가입자 과실 시 사기율 7.89% / 제3자 과실 시 0.88%	전체 사기의 약 96%가 가입자 본인 과실 사고에서 발생. 사기범은 사고를 직접 통제해야 하므로 타인 과실 사고에서는 범행이 어려움
PolicyType	스포츠카-충돌보험 13.79%, 세단-종합보험 10.05% (책임보험 0.7% 미만)	본인 차량 수리비를 받는 종합·충돌 보험에 사기가 집중. 타인만 보상하는 책임보험은 이득이 없어 사기가 거의 없음
Deductible (자기 부담금)	500 달러 그룹의 사기율 17.87% (전체 평균의 3배)	보험사 의심을 피하면서 보상금을 극대화할 수 있는 “적당한” 구간을 전략적으로 선택
AddressChange_Claim	주소 변경 이력 “없음(No Change)” 집단에서 825건 발생 (압도적)	사기범들은 의심받기 쉬운 행동을 자제하고 평범한 거주 상태를 유지한 채 범행
PastNumberOfClaims	1~4회 청구 이력자가 무이력자보다 사기 건수 많음	“한 번 해보니 됐다”는 학습 효과. 과거 청구 경험이 재범 확률을 높임
AgentType	외부 대리점 (External) 가입자에서 사기 건수 압도적	외부 대리점 심사가 내부 직원 채널보다 상대적으로 느슨한 점을 악용
VehiclePrice	20,000~29,000 달러 구간 대중 차량에 사기 집중	초고가 차량은 조사 까다롭고 저가 차량은 보상금 적음. 환금성 좋은 중저가 차량 선호
Days_Policy_Accident	가입 후 30일 초과 집단에서 사기 건수 대부분	가입 직후 사고는 즉시 조사 대상이므로 일정 기간 후 정상 사고로 위장
AgeOfVehicle	6년, 7년, 7년 초과 노후 차량에서 사기 집중	신차 대비 보상 심사가 덜 엄격하고 파손 이력 은폐 용이

결과를 종합하면, 이 데이터셋에서 보험 사기는 (1) 가입자 본인 과실 사고, (2) 종합·충돌형 보험, (3) 주소 변경 이력 없음, (4) 과거 청구 이력 적음, (5) 외부 대리점 계약, (6) 2만 달러대 중저가 차량, (7) 가입 후 30일 초과 사고, (8) 6~7년 이상의 노후 차량이라는 특성이 겹칠수록 발생 건수가 높아지는 복합 패턴을 보인다. 이는 사기범들이 의심을 살 만한 행동을 철저히 피하고 “평범하고 오래된 가입자”로 위장하여 범행을 시도하고 있음을 시사한다.




그림 3.1: PolicyType별 사기 건수 및 사기율




그림 3.2: Fault · Deductible · AddressChange_Claim 별 사기율




그림 3.3: VehiclePrice · PastNumberOfClaims · MonthClaimed 별 사기 분포




그림 3.4: AccidentArea · AgeOfPolicyHolder · Sex 별 사기 분포




그림 3.5: AgentType·Year·Days_Policy_Accident 별 사기 분포

3.3.4 변수-사기 간 상관관계 분석

모든 수치 변환이 완료된 데이터를 바탕으로 각 독립변수와 사기 여부(FraudFound_P) 사이의 피어슨 상관계수를 산출하였다. 주요 결과는 표 3.6에 정리하였다.

표 3.6: 주요 변수와 사기 여부 간 피어슨 상관계수

변수명	상관계수	해석
Fault (가입자 과실)	+0.131	가장 높은 양의 상관
VehicleCategory_Sedan	+0.122	세단 차종 사기 발생 정의 관계
BasePolicy_All Perils	+0.112	종합보험 가입자 사기 경향 높음
VehiclePrice	+0.038	차량 가격이 높을수록 사기 소폭 증가
Days_Policy_Accident	-0.025	가입 후 사고까지 짧을수록 사기 확률 증가
PastNumberOfClaims	-0.057	청구 이력이 적을수록 사기 집중
VehicleCategory_Sport	-0.136	스포츠카는 사기 적발률 낮음
BasePolicy_Liability	-0.154	가장 강한 음의 상관 (책임보험은 사기 동기 약함)




그림 3.6: 전체 변수와 FraudFound_P 간 피어슨 상관계수

상관분석 결과, 과실 여부(Fault, +0.131)가 가장 높은 양의 상관관계를 기록하여 앞선 분석들과 일관된 결과를 보였다. 이는 가입자가 사고 상황을 직접 통제할 수 있는 본인 과실 사고에서 사기 시도가 집중됨을 의미한다.

특이사항으로 책임보험(BasePolicy_Liability, -0.154)은 전체 변수 중 가장 강력한 음의 상관관계를 나타냈다. 책임보험은 가입자 본인이 수령할 수 있는 보상금이 없기 때문에 사기 동기가 현저히 낮아지는 것으로 보이며, 이는 해당 변수가 “사기 가능성이 낮음”을 나타내는 유의미한 지표임을 시사한다. 반면, 본인 차량 손해를 보장하는 종합

보험 (All Perils, +0.112)은 사고와 양의 상관관계를 보였다. 또한 스포츠카(VehicleCategory_Sport, -0.136)도 강한 음의 상관관계를 기록하였는데, 이는 차량 가격이 높아 사고 시 보험사의 조사가 까다로운 차종일수록 사고 시도가 억제되는 경향이 데이터에 반영된 결과로 풀이된다.

Chapter 4

방법론

4.1 Logit Adjustment의 수학적 정의

본 연구는 Menon et al. (2021)의 *post-hoc Logit Adjustment* 기법을 채택한다. 이항 분류 환경에서 학습된 분류기가 출력하는 사후확률을 $\hat{p}(y = 1 | x)$ 라 할 때, 표준 logit은 다음과 같이 정의된다.

$$f(x) = \log \frac{\hat{p}(y = 1 | x)}{\hat{p}(y = 0 | x)}. \quad (4.1)$$

학습 데이터의 사전확률을 $\pi_1 = P(y = 1)$, $\pi_0 = 1 - \pi_1$ 이라 하면, Bayes 정리에 의해 학습 분포의 logit은 클래스 조건부 우도비와 사전확률 log-odds의 합으로 분해된다.

$$f(x) = \underbrace{\log \frac{P(x | y = 1)}{P(x | y = 0)}}_{\text{우도비 (생성적 항)}} + \underbrace{\log \frac{\pi_1}{\pi_0}}_{\text{사전확률 편향}}. \quad (4.2)$$

평가 환경에서 사전확률이 균형($\pi_1 = \pi_0 = 0.5$)이라면 두 번째 항은 0이 되어야 하지만, 본 연구의 학습 분포에서는 $\pi_1 = 0.0598$ 이므로 logit에 $\log(0.0598/0.9402) \approx -2.755$ 의 음의 편향이 더해진다. 이를 사후에 제거하는 것이 Logit Adjustment의 본질이다. 온도 매개변수 $\tau \geq 0$ 을 도입한 보정식은 다음과 같다.

$$\boxed{f_{\text{adj}}(x) = f(x) - \tau \cdot \log \frac{\pi_1}{\pi_0}} \quad (4.3)$$

확률 형태로 환원하면,

$$\hat{p}_{\text{adj}}(x) = \sigma \left(f(x) - \tau \cdot \log \frac{\pi_1}{\pi_0} \right), \quad (4.4)$$

여기서 $\sigma(\cdot)$ 은 시그모이드 함수이다. $\tau = 1$ 은 Bayes 정리에 따른 정확한 사전확률 보정이며, 본 연구는 이를 기본값으로 사용한다.

단조변환 성질 식 (4.3)은 모든 입력 x 에 동일한 상수를 더하는 단조변환이다. 따라서 예측값의 순위 (*ranking*)는 보존되며, PR-AUC와 같은 ranking 기반 지표는 보정 전후 동일하다. 반면 임계값 기반 지표 (Recall, Precision, F_2 , Cost)들은 변경될 수 있다. 이는 Logit Adjustment가 모델의 판별력 자체를 변화시키지 않고 결정 경계의 위치에 영향을 주는 방식으로 작동하는 것임을 의미한다.

4.1.1 판별적 접근과 생성적 접근의 융합

분류 모델은 학습 방식에 따라 두 부류로 나뉜다. **생성적 모델(Generative Model)**은 결합 분포 $P(x, y)$ 를 먼저 추정한 뒤 Bayes 정리로 $P(y | x)$ 를 도출한다. 이 과정에서 사전 확률 $\pi_y = P(y)$ 가 명시적으로 분리되어 처리된다. 따라서 학습 분포와 평가 분포의 π 가 다를 때, 두 번째 항만 교체하면 손쉽게 보정이 가능하다. **판별적 모델(Discriminative Model)**은 $P(y | x)$ 를 직접 학습한다. Logistic Regression, Random Forest, CatBoost 등 본 연구에서 사용하는 모든 모델이 이 범주에 속한다. 판별적 모델은 π 를 별도로 추정하지 않으므로, 학습 과정에서 π 가 $f(x)$ 안에 암묵적으로 흡수된다.

식 (4.2)은 이 구조를 명확히 드러낸다. 판별적 모델이 학습하는 $f(x)$ 의 첫 번째 항은 클래스 조건부 우도비로, 생성적 모델이 명시적으로 추정하는 항과 동일하다. 두 번째 항은 학습 분포의 사전확률 편향이다. 클래스 불균형 환경($\pi_1 \ll 0.5$)에서는 이 두 번째 항이 $f(x)$ 를 음수 방향으로 강하게 끌어당겨 결정 경계를 다수 클래스 쪽으로 체계적으로 밀어낸다.

Logit Adjustment는 이 두 번째 항을 사후에 빼줌으로써, **판별적으로 학습하되 결정 단계에서는 생성적 관점의 사전확률 보정을 명시적으로 적용하는 두 접근의 융합**을 실현한다. 데이터를 변경하지 않고, 추가 학습 비용 없이, 단일 상수의 연산만으로 이 융합이 가능하다는 점이 실용적 장점이다.

4.2 비교 방법론

본 연구는 클래스 불균형 보정의 세 가지 접근을 비교한다.

- **Baseline:** 보정 없음. 표준 분류기에 임계값 0.5를 적용.
- **Class Weighted:** 학습 단계 보정. 손실함수에서 소수 클래스 샘플의 가중치를 $1/\pi_y$ 로 부여 (`class_weight='balanced', auto_class_weights='Balanced'`).
- **Logit Adjustment ($\tau = 1$):** 사후 보정. 식 (4.3)을 적용. 임계값은 0.5 유지.

세 방법의 본질적 차이는 **보정이 적용되는 단계**이다. Class Weighted는 손실함수를 변경하여 학습된 모델 $\hat{f}(x)$ 자체를 다르게 만들고, Logit Adjustment는 학습된 $\hat{f}(x)$ 를 그대로 두고 결정 단계에서만 보정한다. 이로 인해 Baseline과 Logit Adjustment의 비교에서는 학습된 모델이 동일하게 유지되어 보정 효과를 순수하게 분리할 수 있는 장점이 있다. 임계값은 세 방법 모두 0.5로 고정하였다. 이는 Logit Adjustment가 사전확률 보정만으로 임계값 이동 효과를 달성하는지 순수하게 측정하기 위함이다.

4.3 비대칭 오분류 비용 지표

본 연구는 사기 탐지의 비대칭 오분류 비용을 반영하기 위해 다음의 경험적 비용 지표 (Cost)를 추가 평가 지표로 사용한다.

$$\text{Cost} = \frac{C_{FN} \cdot \text{FN} + C_{FP} \cdot \text{FP}}{N}, \quad (4.5)$$

여기서 C_{FN} 은 사기를 정상으로 잘못 분류했을 때의 비용, C_{FP} 은 정상을 사기로 잘못 분류했을 때의 비용이다. 본 연구는 도메인 가정으로 $C_{FN}/C_{FP} = 10/1$ 을 채택하였다. 이는 사기 1건 미탐지의 손실이 정상 1건 오탐지의 약 10배에 해당한다는 가정이며, 실제 보험사 운영 환경에서는 평균 사기 청구액과 오탐 처리 비용을 기반으로 산출해야 하므로 본 연구의 한계로 명시한다.

K-Fold 비교와의 연결 K-Fold 교차검증에서 비용 지표의 평균값(μ)은 모델의 체계적 편향을, 표준편차(σ)는 폴드 간 성능 변동성을 반영하는 것으로 해석한다. 본 연구는 이를 통해 두 보정 방법의 안정성을 비교한다.

4.4 모델 평가 지표

사기 탐지처럼 한쪽 클래스가 압도적으로 많은 상황에서는 단순 정확도 (Accuracy) 만으로 모델을 평가하면 실제 탐지 성능을 왜곡할 수 있다. 이에 다음 지표들을 함께 사용한다.

정밀도 (Precision)는 모델이 “사기”라고 예측한 건수 중 실제로 사기인 비율이고, 재현율 (Recall)은 실제 사기 건수 중 모델이 “사기”로 올바르게 찾아낸 비율이다.

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}. \quad (4.6)$$

F_2 -Score는 Recall에 두 배 가중치를 부여한 지표로, 사기 탐지처럼 재현율이 중요한 문제에 적합하다.

$$F_2 = \frac{5 \cdot \text{Precision} \cdot \text{Recall}}{4 \cdot \text{Precision} + \text{Recall}}. \quad (4.7)$$

G-Mean은 양성 탐지율과 음성 탐지율의 기하평균으로, 두 클래스를 균형 있게 탐지하는지 측정한다.

$$\text{G-Mean} = \sqrt{\text{TPR} \cdot \text{TNR}}. \quad (4.8)$$

PR-AUC는 Precision-Recall 곡선 아래 면적으로, 극단 불균형 환경에서 ROC-AUC보다 정직한 지표이다. 본 연구는 Recall, F_2 , G-Mean, PR-AUC, 그리고 비대칭 오분류 비용 지표 (Cost)를 평가 기준으로 삼는다.

Chapter 5

모델 학습 및 결과

5.1 실험 설계

실험은 Stratified Train(80%) / Test(20%) 분할을 기본으로 하며, Train 80% 위에서 Stratified 5-Fold 교차검증을 수행하여 일반화 성능의 평균과 표준편차를 측정하였다. Test 20%는 최종 Holdout 평가에만 사용되며, 모델 선택 과정에서 격리되었다.

비교 모델로는 Elastic Net Logistic Regression, Random Forest, CatBoost를 채택하였다. 세 모델은 각각 선형 판별 모델, 배깅 기반 앙상블, 부스팅 기반 앙상블이라는 서로 다른 학습 패러다임을 대표한다. 이는 Logit Adjustment의 효과가 특정 모델 구조에 의존하지 않고 범용적으로 성립하는지 검증하기 위함이다. 특히 CatBoost는 범주형 변수가 많은 본 데이터셋의 구조에 적합한 Ordered Target Encoding을 내장하고 있으며, Elastic Net은 67개 고차원 One-Hot 변수 환경에서 $L_1 + L_2$ 정규화를 통한 변수 선택 효과를 제공한다.

5.1.1 하이퍼파라미터 탐색

Elastic Net Logistic Regression의 정규화 파라미터는 Train 데이터에 대한 Stratified 5-Fold GridSearch로 결정하였다. 탐색 범위는 $l1_ratio \in \{0.2, 0.5, 0.8\}$, $C \in \{0.01, 0.1, 1, 10\}$ 이며, PR-AUC를 기준으로 최적값을 선택하였다. 결과는 표 5.1와 같다.

표 5.1: Elastic Net LR GridSearch 결과 (PR-AUC, 5-Fold CV 평균)

l1_ratio	C			
	0.01	0.10	1.00	10.00
<i>Baseline (class_weight=None)</i>				
0.2	0.1706	0.1679	0.1670	0.1665
0.5	0.1632	0.1688	0.1672	0.1665
0.8	0.1405	0.1693	0.1674	0.1666
<i>Weighted (class_weight='balanced')</i>				
0.2	0.1623	0.1605	0.1601	0.1601
0.5	0.1627	0.1599	0.1602	0.1601
0.8	0.1617	0.1602	0.1602	0.1602

최적 파라미터는 Baseline에서 $C=0.01$, $l1_ratio=0.2$, Weighted에서 $C=0.01$, $l1_ratio=0.5$ 로 결정되었으며, 두 경우 모두 강한 정규화($C = 0.01$)가 선호되었다. Random Forest는

$n_estimators=400$, CatBoost는 ($iterations=400$, $depth=6$, $learning_rate=0.05$)로 고정하였다.

5.2 성능 결과

5.2.1 Holdout 평가 결과

Test 20% Holdout에 대한 세 방법론의 성능을 표 5.2에 정리하였다.

표 5.2: Holdout(Test 20%) 성능 비교

Model	Variant	Recall	F_2	G-Mean	PR-AUC	Cost
Elastic Net LR	Baseline	0.0000	0.0000	0.0000	0.1827	0.5999
Elastic Net LR	Class_Weighted	0.9351	0.4125	0.7438	0.1623	0.4228
Elastic Net LR	LogitAdj($\tau=1$)	0.9297	0.4097	0.7410	0.1827	0.4270
Random Forest	Baseline	0.0108	0.0135	0.1040	0.2453	0.5934
Random Forest	Class_Weighted	0.0054	0.0067	0.0735	0.2464	0.5966
Random Forest	LogitAdj($\tau=1$)	0.9081	0.4138	0.7461	0.2453	0.4189
CatBoost	Baseline	0.0378	0.0467	0.1944	0.2753	0.5781
CatBoost	Class_Weighted	0.6595	0.4580	0.7433	0.2506	0.3567
CatBoost	LogitAdj($\tau=1$)	0.8703	0.4792	0.7978	0.2753	0.3304




그림 5.1: Holdout 비용 지표(Cost) 비교 ($C_{FN}=10$, $C_{FP}=1$)

핵심 결과를 정리하면 다음과 같다.

(1) **Baseline의 극심한 다수결 편향** Elastic Net LR Baseline의 Recall은 0%로, 단 한 건의 사기도 탐지하지 못하였다. Random Forest와 CatBoost도 Recall 1.1%, 3.8%로 사실상 무력화된 상태이다. 이는 임계값 0.5에서 사기 클래스의 사후확률이 거의 0.5 미만에 분포함을 의미하며, 4.1 절의 식 (4.2)에서 분석한 사전확률 편향이 실제로 결정 경계를 다수인 정상클래스 방향으로 밀어내어 해당 방향으로 체계적으로 편향되었다. 그로 인해 사기 클래스에 대한 예측 확률이 0.5 미만에 분포하게 되었고 Recall이 매우 낮아졌다.

(2) **Logit Adjustment의 모델 무관 안정성** LR, RF, CatBoost 모두에서 Recall 87~93%로 일관된 성능을 보였다. 특히 CatBoost + LogitAdj 조합이 비용 지표 0.3304로 모든 조합 중 최저값을 달성하여 Baseline 대비 42.9% 감소하였다. 이는 Logit Adjustment가 모델 내부의 학습 자체를 바꾸기보다 prior를 기반으로 사후 logit을 조정하기 때문이라고 판단된다. 즉, 특정 학습 방법 자체에 강하게 의존하지 않아 세 가지 서로 다른 학습 패러다임의 모델에서 일관되게 작동하여 Recall을 포함한 모든 평가지표 측면에서 더 나은 성능을 가진 것으로 보인다.

(3) **Class Weighted의 모델 의존성** LR과 CatBoost에서는 작동했으나, Random Forest에서는 Recall 0.54%로 오히려 Baseline보다 못한 결과를 보였다. 이는 클래스 가중치 부여 방식이 모델 내부 구조와 어떻게 상호작용하느냐에 따라 효과가 달라질 수 있음을 시사하며, 정확한 원인 규명은 추가 분석이 필요하다. 반면 Logit Adjustment는 학습 이후에 사후 logit 조정을 수행하여 모델에 덜 의존적인 경향을 보이며 세 모델에서 비교적 일관된 성능을 보였다.

(4) **PR-AUC의 보존** Baseline과 LogitAdj의 PR-AUC가 모든 모델에서 동일하다 (LR 0.1827, RF 0.2453, CatBoost 0.2753). 이는 4.1 절의 단조변환 성질을 가지기 때문이라고 해석할 수 있다. 즉, Logit Adjustment가 모델의 판별력 자체를 변화시키지 않고 결정 임계값의 위치에 영향을 주어 이동 시킨다는 이론적 예측과 부합한다.

(5) **Precision 감소와 FP 증가의 Trade-off** Recall의 증가와 동시에 Precision은 전반적으로 감소하였다. 이는 더 많은 사기를 탐지하는 과정에서 False Positive(FP)가 증가한 자연스런 결과이다. 특히 Logit Adjustment는 기존에 정상 거래로 분류되던 경계 근처 샘플 일부를 사기 클래스로 분류하므로 FP의 증가를 피할 수 없다. 그러나 본 연구의 비용 측면에선 False Negative의 비용을 False Positive 비용보다 훨씬 크게 설정하였다. 따라서 일부 FP 증가에 따른 비용보다 FN 감소를 통해 얻게 되는 비용 절감 효과가 훨씬 크게 작용한다.

5.2.2 5-Fold 교차검증: 일반화 안정성

CatBoost를 기준으로 5-Fold 교차검증의 평균과 표준편차를 표 5.3에 제시한다.

표 5.3: CatBoost 5-Fold 교차검증 결과 ($\mu \pm \sigma$)

Variant	$\mu(\text{Cost})$	$\sigma(\text{Cost})$	$\mu(\text{G-Mean})$
Baseline	0.5727	0.0068	0.2098
Class_Weighted	0.3814	0.0149	0.7116
LogitAdj($\tau=1$)	0.3338	0.0082	0.7952




그림 5.2: 5-Fold 교차검증 결과

비용 지표 평균값 비교에서 Baseline의 $\mu = 0.5727$ 은 사기를 거의 탐지하지 못해 비용 지표가 가장 높게 나타난 결과이다. 모든 양성 샘플이 손실로 누적된 것이다. Class Weighted는 0.3814로 감소하였고, LogitAdj는 0.3338로 가장 큰 감소를 보였다.

표준편차 비교가 더 중요하다. Class Weighted의 $\sigma = 0.0149$ 는 LogitAdj의 $\sigma = 0.0082$ 의 약 1.8배이다. 이는 Class Weighted가 손실함수를 변경하여 학습된 $\hat{f}(x)$ 자체가 달라지고, 그 결과 모델이 데이터 분할에 더 민감해진 것으로 해석된다. 반면 LogitAdj는 학습된 모델을 Baseline과 동일하게 유지하고 사후에 단조변환만 적용하므로, 폴드 간 변동성 측면에서 Baseline에 가까운 안정성을 유지한다.

종합하면, Logit Adjustment는 비용 지표 평균($\mu=0.3338$)이 가장 낮으면서도 표준편차($\sigma=0.0082$)도 안정적으로 유지하였다. 이는 4.3절에서 서술한 K-Fold 비교 관점과 부합한다.

5.2.3 보정 전후 확률 분포 변화

보정의 효과를 직관적으로 이해하기 위해 Holdout 데이터에서 예측 확률 분포 변화를 살펴본다. CatBoost 기준 결과는 그림 5.3 및 그림 5.4와 같다.

보정 전 사기 샘플의 평균 확률은 약 0.17이며, 임계값 0.5 기준으로 185건 중 7건만이 검출되었다(검출률 3.8%). 보정 후 평균 확률은 0.69로 상승하여 161건이 검출되었다(검출률 87.0%). 이는 logit 이 +2.755만큼 평행이동한 결과로, 분포의 형태는 유지하면서 위치(평균)만 이동시킨 것이다. 이 단조변환 성질이 PR-AUC가 보정 전후 동일하게 유지되는 이유이다.




그림 5.3: Baseline 대비 LogitAdj 보정 후 예측 확률 분포 변화




그림 5.4: Class Weighted vs LogitAdj 예측 확률 분포 비교

그림 5.4에서 두 방법론의 분포 차이를 확인할 수 있다. Class Weighted는 사기 분포가 0.5 양쪽에 분산되어 있어 검출률 65.9%에 그친 반면, LogitAdj는 사기 분포가 0.5 오른쪽에 집중되어 87.0%를 달성하였다.

5.2.4 최종 모델 Confusion Matrix




그림 5.5: 최종 모델의 Holdout Confusion Matrix

최종 모델인 CatBoost + LogitAdj($\tau = 1$)의 Holdout Confusion Matrix는 그림 5.5과 같다. 사기 185건 중 161건을 검출하여 Recall 87.0%를 달성하였으며, FN(미탐) 24건, FP(오탐) 779건이 발생하였다. $C_{FN}/C_{FP} = 10$ 의 비대칭 비용 구조에서 FN 1건은 FP 10건과 동등한 손실에 해당하므로, 24건의 FN은 240건의 FP에 상응하는 비용이다. 실제 FP 779건은 이보다 크지만 비용 지표 관점에서 균형 잡힌 결과임을 확인할 수 있다.

Chapter 6

변수 중요도 분석

본 장에서는 최종 모델인 CatBoost가 어떤 변수를 중요하게 학습했는지 분석한다. 중요한 점은 Logit Adjustment가 모델 학습에 개입하지 않으므로 **Baseline**과 **LogitAdj**의 변수 중요도가 완전히 동일하다는 사실이다. 따라서 비교 대상은 “LogitAdj(=Baseline) vs Class Weighted”이다.

6.1 Top 15 변수 비교

CatBoost 내장 Feature Importance 기준 상위 15개 변수를 그림 6.1에 비교하였다.




그림 6.1: CatBoost Feature Importance Top 15 비교

두 모델 모두 **Fault**를 1위로 꼽았으며, **Year**를 2위로 일관되게 꼽았다. 이는 불균형 보정 방법과 무관하게 모델이 핵심으로 인식하는 변수가 동일함을 시사한다. 다만 **Year**가 2위로 나타난 것은 데이터 수집 시점(1994~1996)에 따른 연도별 사기 빈도 차이를 학습한 결과로 판단되며, 연도 자체가 사기의 인과적 원인이 아니므로 실제 운영 환경에서의 일반화에 한계가 있을 수 있다.

6.2 도메인 검증

모델이 학습한 패턴이 도메인 지식과 일치하는지 검증하기 위해 핵심 변수의 실제 사기율을 확인하였다.

- **Fault:** Policy Holder일 때 사기율 7.89%, Third Party일 때 0.88% — 약 **8.9배** 차이
- **BasePolicy:** All Perils 10.16%, Collision 7.30%, Liability 0.72%

Fault=Policy Holder의 사기율이 Third Party의 8.9배에 달하는 것은 가입자가 사고 상황을 통제할 수 있는 본인 과실 사고에 사기 시도가 집중된다는 도메인 직관과 부합한다. CatBoost가 Fault를 1순위 변수로 학습한 것은 실제 데이터 패턴을 반영한 결과로 볼 수 있으며, 3.3.4절의 피어슨 상관계수 분석(+0.131)과도 일관된다.

Chapter 7

결론

7.1 요약

본 연구는 자동차 보험 사기 탐지의 극심한 클래스 불균형 (5.99%) 문제에 대해 Menon et al. (2021)의 Logit Adjustment를 적용하고, Baseline 및 Class Weighted 방식과 비교 분석하였다. 주요 결과는 다음과 같다.

첫째, CatBoost + Logit Adjustment 조합이 Holdout 비용 지표 0.3304로 최저값을 달성하였다. 이는 Baseline(0.5781) 대비 **42.9%** 감소, Class Weighted(0.3567) 대비 **7.4%** 감소이다. 데이터 증강 없이 사전확률 보정만으로 이러한 개선을 달성한 점이 본 연구의 핵심 결과이다.

둘째, Logit Adjustment는 판별적 모델이 학습한 logit에서 사전확률 편향 항을 사후에 제거함으로써, 판별적 학습과 생성적 관점에서의 사전확률 보정을 단일 연산 안에서 융합하여 사후 확률에 대한 편향을 완화시킨다. 이 구조적 특성이 5-Fold 비용 지표 표준편차 $\sigma(\text{Cost}) = 0.0082$ 로 Class Weighted의 $\sigma = 0.0149$ 의 절반에 머문 결과로 이어졌다. 이는 Logit Adjustment가 데이터 분할의 변화에 대해서 상대적으로 덜 민감하고 안정적인 특성을 가진다는 것을 시사한다.

셋째, LogitAdj는 LR, RF, CatBoost 세 모델 모두에서 일관되게 작동하였다. 반면 Class Weighted는 Random Forest에서 Recall 0.54%로 비교적 낮은 성능이 관찰되어 모델 구조의 의존성이 있음을 확인하였다. 이는 실제 운영 환경에서 Logit Adjustment가 클래스 불균형 데이터 환경 기법 중에서 더 안정적인 선택일 가능성을 시사한다.

넷째, 변수 중요도 분석 결과 모델은 Fault를 1순위로 학습하였으며, 이는 도메인 검증 (Policy Holder의 실제 사기율이 Third Party의 8.9배)과 부합하였다. 모델이 학습한 패턴이 도메인 지식과 일관된 결과를 보임을 확인하였다.

본 연구의 결과는 Logit Adjustment가 복잡한 데이터 전처리나 모델 구조 변경 없이 사전확률 보정만으로 적용 가능하다는 점에서, 실제 보험사 탐지 시스템에 도입 가능한 실용적 방법론임을 시사한다. 특히 세 가지 이질적인 모델 패러다임 모두에서 일관된 성능 개선이 관찰된 것은, 이 방법의 범용성을 뒷받침하는 실증적 근거가 된다.

7.2 한계 및 향후 과제

본 연구는 다음과 같은 한계를 가진다.

(1) **비용 비율의 도메인 가정** $C_{FN}/C_{FP} = 10/1$ 은 도메인 직관에 기반한 가정이며 실제 보험사 운영 비용에서 도출된 값이 아니다. 실제 환경에서는 평균 사기 청구액과 오탐 처리 비용을 기반으로 이 비율을 산출해야 하며, 비율 변화에 따른 민감도 분석이 향후 과제이다.

(2) **τ 튜닝 미반영** 본 연구는 $\tau = 1$ 을 기본값으로 사용하였다. Menon et al. (2021)은 모델의 캘리브레이션이 잘 되어 있지 않은 경우 $\tau \neq 1$ 이 더 좋을 수 있음을 지적하였다. 본 연구는 CatBoost의 확률 보정(calibration) 품질을 별도로 검증하지 않았으며, $\tau = 1$ 의 우수한 성능이 모델의 확률이 잘 보정되어 있기 때문인지 아니면 본 데이터셋의 특성에 의한 것인지는 추가 분석이 필요하다. 본 데이터에서의 최적 τ 탐색은 향후 과제로 남긴다.

(3) **시계열 구조 미반영** 본 연구는 i.i.d. Stratified 분할을 사용하였다. 실제 사기 패턴은 시간적 의존성을 가질 수 있으며, Year 변수가 Top 2 중요도를 차지한 것은 모델이 시간적 편향을 학습했을 가능성을 시사한다. 시계열 기반 교차검증의 적용이 향후 과제이다.

(4) **단일 데이터셋 기반 실험** 본 연구는 단일 공개 데이터셋(fraud_oracle.csv)에 기반한 실험으로 수행되었으므로, 다른 보험 데이터셋이나 실제 운영 환경에서의 외부 검증이 향후 과제로 남는다.

참고문헌

- Chawla, N.V., Bowyer, K.W., Hall, L.O., & Kegelmeyer, W.P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
- Krawczyk, B. (2016). Learning from imbalanced data: open challenges and future directions. *Progress in Artificial Intelligence*, 5(4), 221–232.
- Menon, A.K., Jayasumana, S., Rawat, A.S., Jain, H., Veit, A., & Kumar, S. (2021). Long-tail learning via logit adjustment. *International Conference on Learning Representations (ICLR)*.
- Mitchell, T. (1997). *Machine Learning*. McGraw-Hill.
- Ngai, E.W.T., Hu, Y., Wong, Y.H., Chen, Y., & Sun, X. (2011). The application of data mining techniques in financial fraud detection: A classification framework and an academic review of literature. *Decision Support Systems*, 50(3), 559–569.
- Bengio, Y., & Grandvalet, Y. (2004). No unbiased estimator of the variance of k-fold cross-validation. *Journal of Machine Learning Research*, 5, 1089–1105.
- Salem, O. (2017). The impact of false negative cost on the performance of cost-sensitive learning: A case study in detecting fraudulent transactions. *International Journal of Intelligent Systems and Applications*